

多任务学习选股模型的改进

华泰研究

2024年5月06日 | 中国内地

深度研究

研究员

SAC No. S0570516010001

SFC No. BPY421

林晓明

linxiaoming@htsc.com

+(86) 755 8208 0134

研究员

SAC No. S0570520080004

SFC No. BRB318

何康, PhD

hekang@htsc.com

+(86) 21 2897 2039

人工智能 78：从预测目标、网络结构、组合优化角度改进多任务学习

本文从预测目标、网络结构、组合优化角度探讨多任务学习选股模型的改进。在多期限收益预测基础上，引入夏普比率作为预测目标；参考腾讯 2020 年发表的 PLE 模型，在 GRU 内部引入多层专家和门控网络；采用多周期优化融合不同期限收益预测。结果表明，改进模型相比基线均有提升，引入 PLE 总体优于引入夏普比率，PLE 结合多周期优化模型在指数增强组合的超额收益上优于大部分对照模型。回溯期 2016-12-30 至 2024-04-30 内，周单边换手 20% 条件下，中证 500 增强组合年化超额收益 18.1%，信息比率 3.05，中证 1000 增强组合年化超额收益 28.7%，信息比率 4.24。

改进方向之一：引入夏普比率，预测目标考虑风险信息

本研究的多任务学习基线模型架构为：针对日 K 线和周 K 线，分别采用多任务 GRU 网络，同时预测未来 10 日和 20 日收益率，预测值求均值视作单因子；针对分钟 K 线，人工构建 50 个因子，采用最大化 10 日 ICIR 法合成；最后将日 K 线、周 K 线和分钟 K 线因子等权合成。基线模型的预测目标仅考虑收益，未考虑风险。改进方向之一采用包含收益和风险信息的夏普比率作为目标，在 10 日和 20 日收益预测基础上，引入 20 日夏普比率预测任务。

改进方向之二：引入 PLE 架构，采用多层专家和门控网络提升表征能力

腾讯 PCG 团队 2020 年提出 PLE (Progressive Layered Extraction) 架构，采用多层专家和门控网络设计，提升特征表征能力。改进方向之二将 PLE 引入基线模型的双层 GRU 网络。其中，第一层的任务共享专家网络和任务特定专家网络接受相同的原始 K 线输入信息，采用单层 GRU 提取浅层特征表征后，通过第一层门控单元进行融合；第二层的任务共享专家网络和任务特定专家网络接受特异的输入信息，采用单层 GRU 提取深层特征表征后，通过第二层门控单元进行融合。门控单元均采用单层 GRU 网络与 Softmax 激活。后续的任务特异层与基线模型一致。

改进方向之三：引入多周期优化，最大化多期收益并限制远期换手

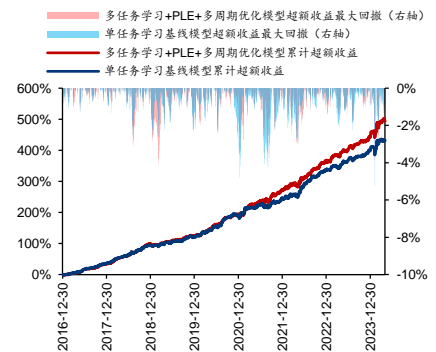
多任务学习同时预测不同期限收益率，基线模型直接求均值作为最终预测，缺点是投资意义不明确。改进方向之三采用多周期优化技术，将 10 日和 20 日收益预测同时输入组合优化器。单周期优化中，每期组合优化的目标函数为最大化预期收益。多周期优化中，目标函数除了最大化预期收益项外，还加入了换手率惩罚项。在最大化组合短期收益和长期收益的同时，限制组合当期换手以及下期可能的换手。

测试结果：三项改进均有效，PLE+多周期优化模型表现出色

测试结果表明，三项改进相比基线均有提升。从 GRU 单因子看，引入夏普比率和引入 PLE 均优于对应的基线。从指数增强组合看，引入 PLE 总体优于引入夏普比率。将“多任务学习+PLE 取 10 日预测”与“多任务学习+PLE 取 20 日预测”的预测值作为多周期优化的输入变量，构建中证 500 和中证 1000 指数增强组合，超额收益优于大部分对照模型，同时在回撤控制上体现出优势。回溯期 2016-12-30 至 2024-04-30 内，周单边换手 20% 条件下，中证 500 增强年化超额收益 18.1%，信息比率 3.05，Calmar 比率 3.22；中证 1000 增强年化超额收益 28.7%，信息比率 4.24，Calmar 比率 6.93。

风险提示：人工智能挖掘市场规律是对历史的总结，市场规律在未来可能失效。人工智能技术存在过拟合风险。深度学习模型受随机数影响较大。本文测试的选股模型调仓频率较高，假定以 vwap 价格成交，忽略其他交易层面因素影响。

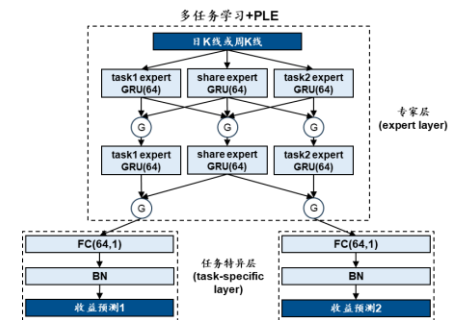
多任务学习中证 1000 增强累计超额



注：股票池：中证全指成分股；回溯区间：2016-12-30 至 2024-04-30；交易费率双边 3‰；周调仓单边换手率上限 20%；优化器约束条件：80% 成分内选股，行业偏离 ±2%，市值偏离 ±0.3

资料来源：Wind，华泰数智中台，华泰研究

基于 PLE 的 GRU 模型网络结构



资料来源：华泰研究

正文目录

研究导读3

多任务学习选股模型的改进5

 基线模型.....5

 预测目标：引入夏普比率7

 网络结构：引入 PLE7

 组合优化：引入多周期优化.....9

测试结果 11

 gru_1day 因子 11

 gru_5day 因子 12

 合成因子和指数增强组合 12

 多周期优化 14

总结 16

 参考文献..... 17

 风险提示..... 17

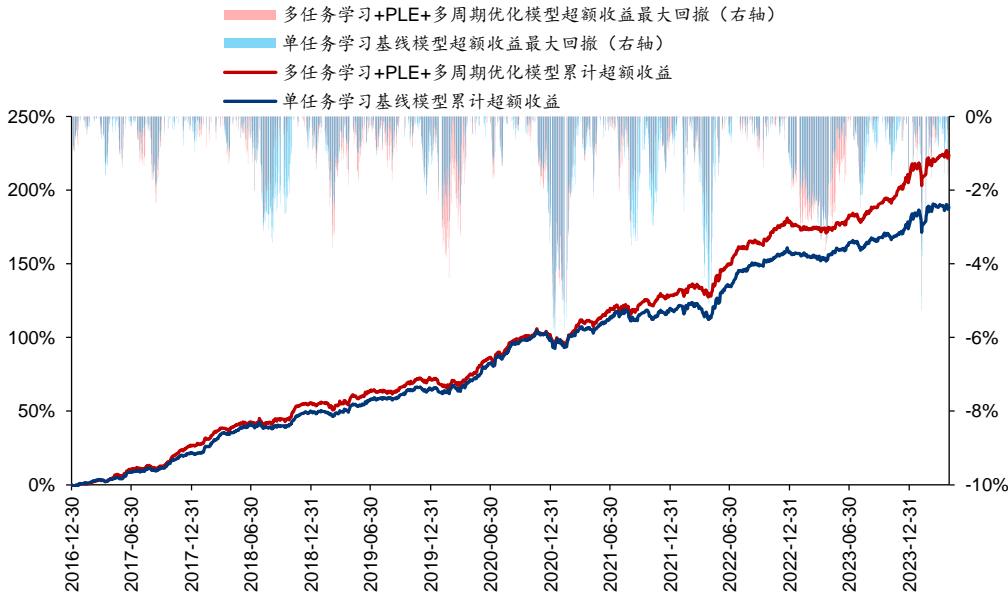
研究导读

华泰金工团队前期研究《AI 模型如何一箭多雕：多任务学习》（2023-05-06）和《基于全频段量价特征的选股模型》（2023-12-08）中，我们采用多任务学习的硬参数共享机制，替代常规的单任务学习，有效提升了选股模型的表现。本研究将从预测目标、网络结构、组合优化三个角度探索多任务学习选股模型的改进。

首先，在原有多期限收益率预测基础上，引入夏普比率作为新增的预测目标；其次，参考腾讯 2020 年发表的 PLE（Progressive Layered Extraction）模型，在原有 GRU 网络内部引入多层专家和门控网络；再次，采用多周期优化（Multi-Period Optimization）融合不同期限的收益预测。测试上述方案在因子和组合层面的改进效果。

结果表明，改进后的模型相比基线均有提升，其中引入 PLE 的效果总体优于引入夏普比率，PLE 结合多周期优化的模型在指数增强组合超额收益上优于大部分对照模型。回测期 2016-12-30 至 2024-04-30 内，周单边换手 20% 条件下，中证 500 增强组合年化超额收益 18.1%，信息比率 3.05，超额收益 Calmar 比率 3.22；中证 1000 增强组合年化超额收益 28.7%，信息比率 4.24，超额收益 Calmar 比率 6.93。

图表1：部分测试模型累计超额收益（基准为中证 500 指数）




注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3
资料来源：Wind，华泰数智中台，华泰研究

图表2：部分测试模型回测绩效（基准为中证 500 指数）

	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
单任务学习基线	16.19%	5.77%	2.80	6.11%	2.65	79.55%	20.33
多任务学习基线	16.46%	5.94%	2.77	5.73%	2.87	76.14%	20.30
多任务学习+夏普比率	17.57%	5.85%	3.00	5.44%	3.23	79.55%	20.37
多任务学习+PLE	17.89%	5.97%	3.00	6.08%	2.94	76.14%	20.31
多任务学习+PLE+多周期优化	18.11%	5.93%	3.05	5.63%	3.22	77.27%	20.29

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3；多任务学习基线、多任务学习+夏普比率、多任务学习+PLE 均取多个预测均值
资料来源：Wind，华泰数智中台，华泰研究

图表3：部分测试模型累计超额收益（基准为中证 1000 指数）



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3
资料来源：Wind，华泰数智中台，华泰研究

图表4：部分测试模型回测绩效（基准为中证 1000 指数）

	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
单任务学习基线	26.71%	6.63%	4.03	5.21%	5.12	87.50%	20.35
多任务学习基线	27.30%	6.85%	3.98	6.26%	4.36	87.50%	20.27
多任务学习+夏普比率	27.98%	6.58%	4.25	5.72%	4.89	88.64%	20.29
多任务学习+PLE	28.60%	6.76%	4.23	4.25%	6.74	93.18%	20.26
多任务学习+PLE+多周期优化	28.72%	6.78%	4.24	4.14%	6.93	93.18%	20.28

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3；多任务学习基线、多任务学习+夏普比率、多任务学习+PLE 均取多个预测均值
资料来源：Wind，华泰数智中台，华泰研究

多任务学习选股模型的改进

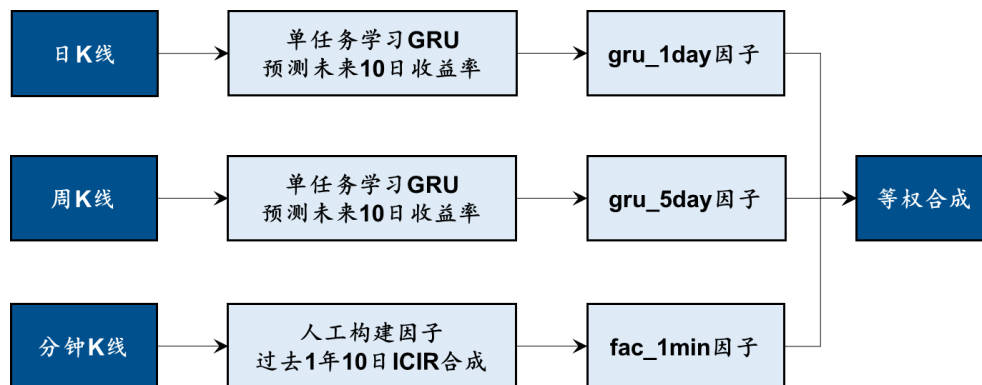
基线模型

本研究设置了单任务学习和多任务学习两类基线模型。单任务学习基线模型的架构为：

1. 对于日 K 线和周 K 线，采用 GRU 模型预测未来 10 日收益率，将预测值作为单因子；
2. 对于分钟 K 线，人工构建 50 个因子，采用最大化 10 日 ICIR 法合成，同样得到单因子；
3. 最后将日 K 线、周 K 线和分钟 K 线因子等权合成。

分钟 K 线因子定义请参考华泰金工研报《高频因子计算的 GPU 加速》（2023-10-16）。

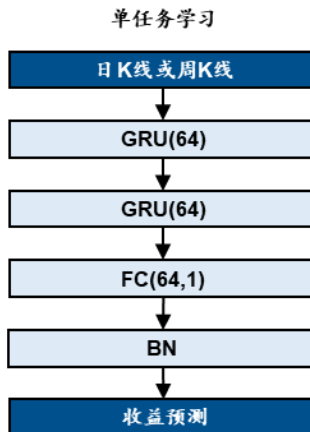
图表5：单任务学习基线模型示意图



资料来源：华泰研究

单任务学习基线中的 GRU 模型采用简单的两层 GRU 网络，如下图。

图表6：单任务学习 GRU 模型网络结构

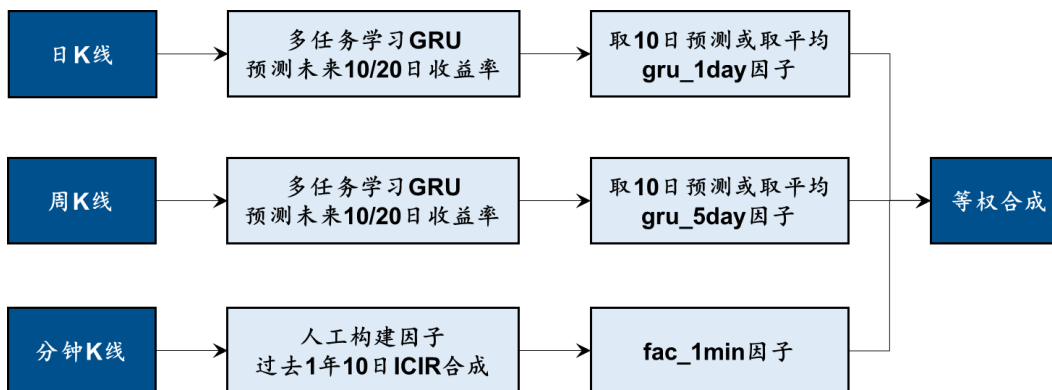


资料来源：华泰研究

传统 AI 预测问题对模型的定位是“专才”，每个模型对应唯一预测目标，执行特定功能，这种学习机制称为单任务学习。然而无论人类还是 AI，“通才”更符合人们对智能的期待。例如我们面对人脸可以同时识别性别和年龄，大语言模型可以对话和写代码。多任务学习正是为训练通才这一目标所设计的学习机制，每个模型对应多个预测目标，同时学习多项任务。多任务学习利用任务间的关联性，共享信息表征，实现知识迁移，提高泛化能力。

本研究中的多任务学习基线模型采用与单任务学习相近的架构。和单任务学习基线模型的主要区别在于：日 K 线和周 K 线模块的 GRU 模型同时预测未来 10 日和 20 日收益率。取 10 日收益预测，或者取两者均值，作为对应模块的单因子。

图表7：多任务学习基线模型示意图



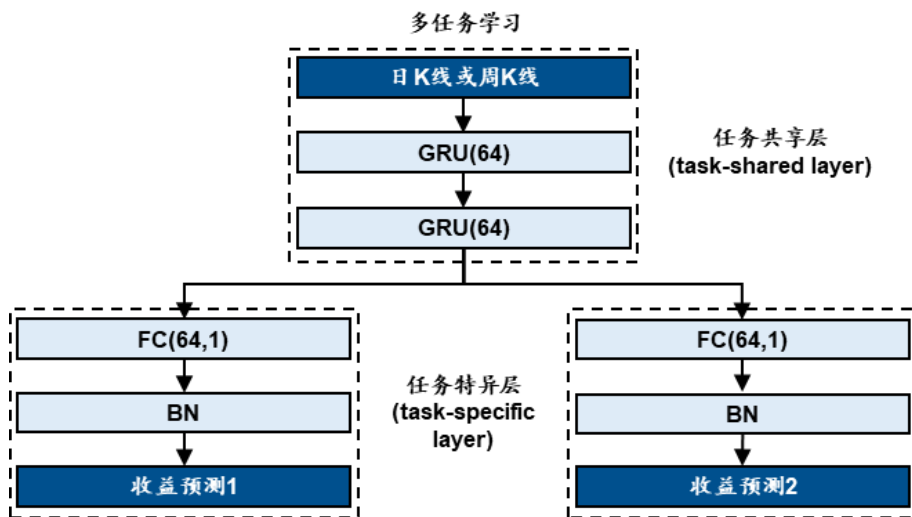
资料来源：华泰研究

多任务学习基线模型中，任务共享层同样采用简单的两层 GRU 网络，任务特异层各自包含一个输出层。多个预测任务的损失函数采用 DWA（Dynamic Weight Average）加权（Liu 等，2018）：

$$\lambda_k(t) = \frac{K \exp\left(\frac{w_k(t-1)}{T}\right)}{\sum_i \exp\left(\frac{w_i(t-1)}{T}\right)}$$
$$w_k(t-1) = \frac{\mathcal{L}_k(t-1)}{\mathcal{L}_k(t-2)}$$

DWA 加权使得不同任务的学习速率尽量保持一致，回溯各任务过去 2 期损失函数值，若 t-1 期相比于 t-2 期高，则给予该任务更高的权重，促进该任务的学习。

图表8：多任务学习 GRU 模型网络结构



资料来源：华泰研究

损失函数为截面 IC 相反数的均值。全部测试均对 5 组随机数种子点训练下的结果求均值。
组合优化和回测设置如下表。

图表9：组合优化和回测设置

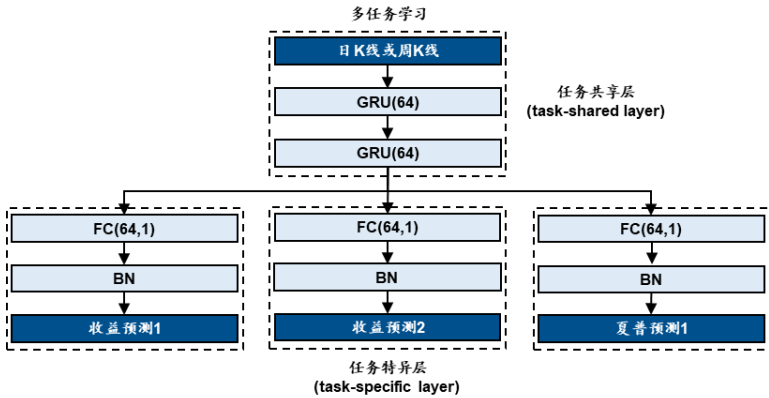
步骤	参数	参数值
构建组合	基准	中证 500 指数，中证 1000 指数
	优化目标	最大化预期收益
	组合仓位	1
	个股权重下限	0
	个股偏离权重约束	[-1%, 1%]
	行业偏离权重约束	[-2%, 2%]
	风格偏离标准差约束	[-0.3, 0.3]
	风格因子	市值
	调仓周期	每 5 个交易日
	单次调仓单边换手率上限	20%
	成分股权重约束下限	80%
回测	起止日期	2016-12-30 至 2024-04-30
	单边费率	0.0015
	交易价格	vwap
	特殊处理	停牌不买入/卖出；一字板涨停不买入；一字板跌停不卖出；其余股票重新分配权重

资料来源：华泰研究

预测目标：引入夏普比率

多任务学习基线模型同时预测不同期限的收益率，仅考虑收益，未考虑风险。考虑到多任务学习要求任务间有相似性，直接预测波动率可能不合理，我们采用包含收益和风险信息的夏普比率作为新的预测目标，网络结构如下图。具体而言，本研究在 10 日和 20 日收益的基础上，引入 20 日夏普比率作为第三项预测任务。不采用 10 日夏普比率的原因是时间区间过短，指标计算容易受到异常值影响。

图表10：多任务学习+夏普比率 GRU 模型网络结构



资料来源：华泰研究

网络结构：引入 PLE

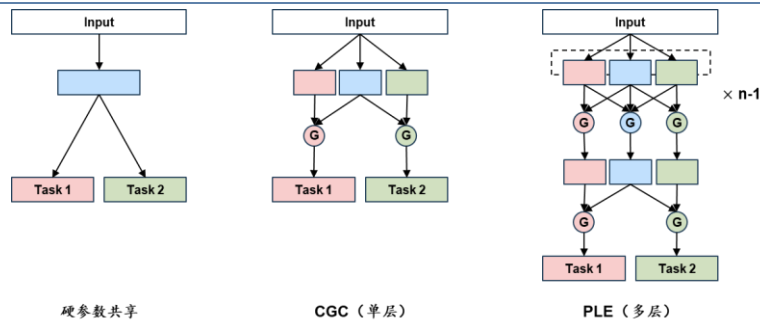
多任务学习基线模型采用经典的硬参数共享机制，任务共享层使用相同网络，结构简单。但由于各任务可能需要针对性的特征表征，硬参数共享会限制模型性能。研究者陆续提出 Cross-Stitch Network（十字绣网络）、Sluice Network（水闸网络）、MMOE（多门专家混合模型）等多任务学习的变式，提升了模型的表征能力。

2020 年，腾讯 PCG（Platform and Content Group）团队提出一种创新的多任务学习网络 PLE（Progressive Layered Extraction），实证测试效果优于硬参数共享、MMOE 等其他形式的多任务学习网络，获得 RecSys2020 会议最佳长论文奖。

PLE 架构如下图，其特色可以总结为以下三点：

1. 两类专家分离。我们可以将任务共享层看成“特征提取专家”。硬参数共享中，只有一位专家，同时应对多项下游任务的特征提取，可能出现“故此失彼”。在 CGC（可视作 PLE 的单层简化版本）和 PLE 中，存在两类专家——任务共享的专家网络（蓝色）和任务特异的专家网络（任务 1 红色，任务 2 绿色），三者分工明确各司其职。子任务的共性部分由任务共享专家学习，个性部分由任务特异专家学习，从而使得特征表征更为灵活和有针对性。
2. 门控网络。任务共享专家网络和任务特异专家网络的输出，通过门控网络 G 动态融合，传递至相应的下游任务。“动态”代表每个样本有其特定的融合权重，取决于 G 的输出。门控网络在华泰金工前期研究《自适应网络：从削足适履到量体裁衣》（2023-12-01）中亦有实践。
3. 多层级专家。有别于 CGC 的单层专家网络，PLE 包含多层专家网络，逐层提取信息。第一层专家接受相同的原始输入，负责提取浅层信息；后续层的专家接受上层传递来的差异化的输入，负责提取深层信息。PLE 的全称 Progressive Layered Extraction——渐进式分层提取即得名于此。

图表11：PLE 示意图



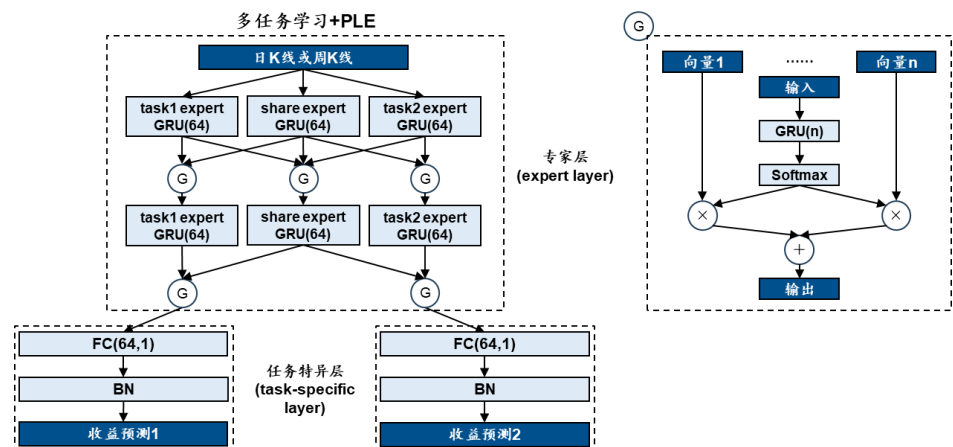
资料来源：Progressive layered extraction (PLE): A novel multi-task learning (MTL) model for personalized recommendations, 华泰研究

原论文中，专家网络和门控网络均采用简单的全连接层。我们将 PLE 思想引入多任务学习基线模型的双层 GRU 网络：

1. 第一层的任务共享专家网络和任务特定专家网络接受相同的原始输入信息，采用单层 GRU 提取浅层特征表征后，通过第一层门控单元进行融合；
2. 第二层的任务共享专家网络和任务特定专家网络接受特异的输入信息，采用单层 GRU 提取深层特征表征后，通过第二层门控单元进行融合；
3. 后续的任务特异层和基线模型一致。

其中门控单元为单层 GRU 网络，以 Softmax 为激活函数。各 GRU 参数均不共享。本研究完整的 PLE 网络结构如下图。

图表12：多任务学习+PLE GRU 模型网络结构



资料来源：华泰研究

组合优化：引入多周期优化

多任务学习模型同时预测不同期限的收益率（本研究选取未来 10 日和 20 日）。基线模型中，我们对多个预测结果采取两种处理方式：

1. 直接取 10 日预测，便于和单任务学习基线模型对照。
2. 取 10 日预测和 20 日预测等权平均。

从前期研究《AI 模型如何一箭多雕：多任务学习》（2023-05-06）结果来看，等权平均整体效果更稳定。但这种处理方式的缺点在于，10 日收益率和 20 日收益率求均值的投资意义不明确。可能的解决方案是采用多周期优化技术，将两组预测值同时输入到组合优化器。Boyd 等人在 2016 年发表论文 *Multi-Period Trading via Convex Optimization*，详细介绍了多周期优化的理论推导和实现方法。本研究使用的多周期优化损失函数是原论文的简化版，省略了持仓成本项和风险项。

单周期优化中，每期组合优化的目标函数为最大化预期收益：

$$\max_w w^T r$$

其中， r 为收益率预测值向量， w 为股票持仓权重向量。组合优化的约束条件包括个股绝对权重、相对权重、行业风格偏离、成分股下限、当期换手率上限等。

多周期优化中，目标函数除最大化预期收益项外，还加入了换手率惩罚项。以双周期优化为例：

$$\max_{w, w_2} w^T u_1 - \lambda_1 \|w - w^-\| + w_2^T u_2 - \lambda_2 \|w_2 - w\|$$

其中， u_1 代表短期收益率预测向量， u_2 代表长期收益率预测中扣除短期收益率预测的部分。例如，假设 u_1 为 T 至 $T+10$ 日区间预期收益（即 T 日收盘价和 $T+10$ 日收盘价之间的区间收益，下同），那么 u_2 应为 $T+10$ 至 $T+20$ 日区间预期收益。本研究中， u_2 需要通过 20 日收益预测值 $r_{t,t+20}$ 和 10 日收益预测值 $r_{t,t+10}$ 推算：

$$u_2 = \frac{r_{t,t+20} + 1}{r_{t,t+10} + 1} - 1$$

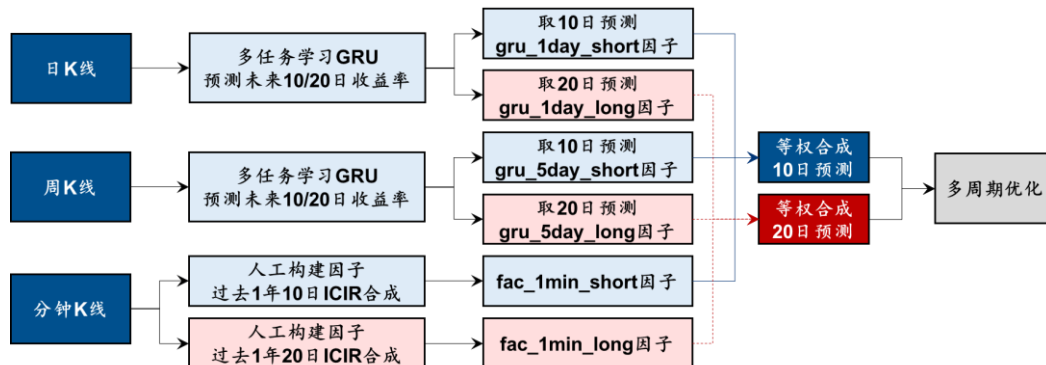
目标函数包含多项与持仓权重有关的变量。其中， w^- 为已实现的上期持仓权重向量； w 为待求解的短周期下的股票当期持仓权重向量； w_2 为待求解的长周期下的股票下期持仓权重向量。目标函数的第二项 $\|w - w^-\|$ 代表实际当期换手率，第四项 $\|w_2 - w\|$ 代表预期下期换手率。组合优化的约束条件同时包含对 w 和 w_2 的约束。

目标函数包含两项自由参数， λ_1 为当期换手惩罚系数， λ_2 为下期换手惩罚系数。本研究中均取 0.2，实际可通过遍历方法进行参数寻优。

总的看，多周期优化的目标函数可以按如下解读：最大化组合短期收益和长期收益的同时，限制组合当期换手以及下期可能的换手。换言之，尽管组合优化器在进行“当下”的求解，但“目光”会更长远。

本研究的多任务学习+多周期优化模型架构如下图。短期预测和长期预测部分均由日 K 线、周 K 线、分钟 K 线三组模块构成，GRU 的预测目标与 ICIR 法的预测区间相匹配。

图表13：多任务学习+多周期优化模型示意图



资料来源：华泰研究

测试结果

测试结果分四部分展示：

1. 引入夏普比率、引入 PLE 对日 K 线 gru_1day 因子在因子层面的改进。
2. 引入夏普比率、引入 PLE 对周 K 线 gru_5day 因子在因子层面的改进。
3. 引入夏普比率、引入 PLE 对合成因子在因子和组合层面的改进。
4. 引入多周期优化在组合层面的改进。

gru_1day 因子

日 K 线 gru_1day 因子的单因子测试结果如下表。考察 RankIC 均值：

1. 多任务学习全面优于单任务学习；
2. 多个预测值取平均优于取 10 日预测；
3. 每种预测值处理方式内部，引入夏普比率和引入 PLE 两者没有鲜明规律，但均优于对应的基线。

其余指标的规律与 RankIC 均值不尽相同。其中 RankICIR、Top 层年化超额收益、对冲组合年化超额收益的规律总体接近。后文不再对其余指标展开解读。


图表14：gru_1day 因子测试指标

	RankIC	RankICIR	RankICT	均值Top	层年化	Bottom 层年	对冲组合年	Top 层夏	Bottom 层	对冲组合	Top 层信息	Top 层年化
	均值		胜率	超额收益	化超额收益	化超额收益	普比率	夏普比率	夏普比率	夏普比率	比率	换手率
单任务学习基线	12.8%	1.31	90.8%	7.16	29.8%	-56.3%	43.1%	1.27	-2.06	3.08	4.25	38.8
多任务学习基线取 10 日预测	12.9%	1.31	90.9%	7.19	29.8%	-56.4%	43.1%	1.27	-2.06	3.08	4.25	38.5
多任务学习+夏普比取 10 日预测	12.9%	1.31	90.9%	7.17	30.8%	-57.0%	43.9%	1.32	-2.09	3.13	4.42	38.5
多任务学习+PLE 取 10 日预测	13.0%	1.32	91.4%	7.23	30.6%	-56.7%	43.7%	1.31	-2.08	3.15	4.45	38.6
多任务学习基线取平均	13.2%	1.32	91.1%	7.30	30.0%	-56.5%	43.3%	1.28	-2.04	2.97	4.22	37.7
多任务学习+夏普比率取平均	13.5%	1.33	91.0%	7.23	30.0%	-56.6%	43.3%	1.32	-2.04	2.92	4.37	37.3
多任务学习+PLE 取平均	13.3%	1.33	91.7%	7.34	30.5%	-56.6%	43.5%	1.31	-2.05	3.00	4.39	37.6

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；预测收益统一使用 T 至 T+10 日收盘价区间收益率；10 日频调仓，不考虑交易费用
资料来源：Wind，华泰数智中台，华泰研究

部分测试因子 Top 层相对净值如下图。

图表15：gru_1day 因子 Top 层相对净值



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；10 日频调仓，不考虑交易费用；Top 层为因子值排名前 10% 个股

资料来源：Wind，华泰数智中台，华泰研究

gru_5day 因子

周 K 线 gru_5day 因子的单因子测试结果如下表。同样考察 RankIC 均值：

1. 除多任务学习基线取 10 日预测外，其余多任务学习均优于单任务学习。
2. 多个预测值取平均优于取 10 日预测；
3. 每种预测值处理方式内部，引入夏普比率和引入 PLE 两者没有鲜明规律，但均优于对应的基线。


图表16：gru_5day 因子测试指标

	RankIC 均值	RankICIR	RankICT 胜率	均值Top 超额收益	层年化 超额收益	Bottom 层年 化超额收益	对冲组合年 化超额收益	Top 层夏 普比率	Bottom 层 夏普比率	对冲组合 夏普比率	Top 层信息 比率	Top 层年化 换手率
单任务学习基线	12.7%	1.24	88.7%	6.74	29.3%	-50.6%	40.0%	1.21	-1.82	2.58	4.00	32.5
多任务学习基线取 10 日预测	12.6%	1.22	88.6%	6.73	28.5%	-50.7%	39.6%	1.17	-1.82	2.50	3.75	31.4
多任务学习+夏普比率取 10 日预测	12.8%	1.24	89.0%	6.74	28.5%	-50.6%	39.6%	1.18	-1.82	2.52	3.80	31.4
多任务学习+PLE 取 10 日预测	12.8%	1.23	88.5%	6.77	30.5%	-50.8%	40.6%	1.26	-1.82	2.56	4.01	31.8
多任务学习基线取平均	13.0%	1.24	88.5%	6.85	28.8%	-51.1%	39.9%	1.19	-1.82	2.50	3.83	30.6
多任务学习+夏普比率取平均	13.5%	1.26	88.9%	6.85	28.8%	-50.4%	39.6%	1.23	-1.79	2.43	3.89	30.6
多任务学习+PLE 取平均	13.2%	1.25	88.6%	6.91	30.9%	-51.4%	41.1%	1.29	-1.83	2.54	4.06	30.9

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；预测收益统一使用 T 至 T+10 日收盘价区间收益率；10 日频调仓，不考虑交易费用
资料来源：Wind，华泰数智中台，华泰研究

部分测试因子 Top 层相对净值如下图。

图表17：gru_5day 因子 Top 层相对净值



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；10 日频调仓，不考虑交易费用；Top 层为因子值排名前 10% 个股

资料来源：Wind，华泰数智中台，华泰研究

合成因子和指数增强组合

日 K 线、周 K 线、分钟 K 线三者等权求均值得到合成因子，单因子测试结果如下表。RankIC 均值的规律与 gru_5day 因子一致，这里不再重复。


图表18：合成因子测试指标

	RankIC 均值	RankICIR	RankICT 胜率	均值Top 超额收益	层年化 超额收益	Bottom 层年 化超额收益	对冲组合年 化超额收益	Top 层夏 普比率	Bottom 层 夏普比率	对冲组合 夏普比率	Top 层信息 比率	Top 层年化 换手率
单任务学习基线	13.9%	1.452	92.7%	7.49	31.4%	-58.1%	44.8%	1.34	-2.16	3.19	4.95	38.0
多任务学习基线取 10 日预测	13.9%	1.449	92.7%	7.50	31.5%	-58.5%	45.0%	1.33	-2.16	3.20	4.96	37.7
多任务学习+夏普比率取 10 日预测	14.0%	1.454	92.8%	7.50	31.5%	-58.5%	45.0%	1.34	-2.17	3.18	4.91	37.6
多任务学习+PLE 取 10 日预测	14.1%	1.453	92.5%	7.53	32.3%	-58.9%	45.6%	1.38	-2.18	3.24	5.07	37.7
多任务学习基线取平均	14.2%	1.445	92.4%	7.56	31.4%	-58.5%	44.9%	1.34	-2.15	3.13	4.96	37.2
多任务学习+夏普比率取平均	14.4%	1.446	92.0%	7.46	30.6%	-58.0%	44.3%	1.33	-2.12	3.02	4.76	36.9
多任务学习+PLE 取平均	14.3%	1.451	92.4%	7.61	32.3%	-58.5%	45.4%	1.38	-2.15	3.14	4.98	37.2

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；预测收益统一使用 T 至 T+10 日收盘价区间收益率；10 日频调仓，不考虑交易费用
资料来源：Wind，华泰数智中台，华泰研究

部分测试因子 Top 层相对净值如下图。

图表19：合成因子 Top 层相对净值



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；10 日频调仓，不考虑交易费用；Top 层为因子值排名前 10% 个股

资料来源：Wind，华泰数智中台，华泰研究

以合成因子构建指数增强组合。中证 500 指数增强组合回测结果如下表。从年化超额收益率、信息比率和超额收益 Calmar 比率看，引入夏普比率和引入 PLE 的回测表现均优于对应的多任务学习基线。从年化超额收益率看，引入 PLE 略优于对应的引入夏普比率模型。

图表20：合成因子指数增强组合回测绩效（基准为中证 500 指数）

	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
单任务学习基线	16.19%	5.77%	2.80	6.11%	2.65	79.55%	20.33
多任务学习基线取 10 日预测	15.27%	5.89%	2.59	6.22%	2.45	75.00%	20.32
多任务学习+夏普比率取 10 日预测	16.75%	5.83%	2.87	6.27%	2.67	80.68%	20.37
多任务学习+PLE 取 10 日预测	17.61%	5.91%	2.98	6.10%	2.88	80.68%	20.34
多任务学习基线取平均	16.46%	5.94%	2.77	5.73%	2.87	76.14%	20.30
多任务学习+夏普比率取平均	17.57%	5.85%	3.00	5.44%	3.23	79.55%	20.37
多任务学习+PLE 取平均	17.89%	5.97%	3.00	6.08%	2.94	76.14%	20.31

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

中证 1000 指数增强组合回测结果如下表。多任务学习+PLE 取平均模型在年化超额收益率、超额收益 Calmar 比率方面优于其余模型，多任务学习+夏普比率取平均模型在信息比率方面优于其余模型。

图表21：合成因子指数增强组合回测绩效（基准为中证 1000 指数）

	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
单任务学习基线	26.71%	6.63%	4.03	5.21%	5.12	87.50%	20.35
多任务学习基线取 10 日预测	26.63%	6.74%	3.95	6.65%	4.00	84.09%	20.30
多任务学习+夏普比率取 10 日预测	25.33%	6.77%	3.74	6.19%	4.09	86.36%	20.30
多任务学习+PLE 取 10 日预测	25.64%	6.66%	3.85	4.64%	5.53	84.09%	20.29
多任务学习基线取平均	27.30%	6.85%	3.98	6.26%	4.36	87.50%	20.27
多任务学习+夏普比率取平均	27.98%	6.58%	4.25	5.72%	4.89	88.64%	20.29
多任务学习+PLE 取平均	28.60%	6.76%	4.23	4.25%	6.74	93.18%	20.26

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

多周期优化

将“多任务学习+PLE 取 10 日预测”与“多任务学习+PLE 取 20 日预测”的预测值作为多周期优化的输入变量，构建指数增强组合。中证 500 指数增强组合回测结果如下表。多周期优化在超额收益和信息比率方面略弱于单独用 20 日预测值构建的组合，但 Calmar 比率优于其他模型，展现出回撤控制上的优势。

需要补充说明，由于我们设置的组合优化器换手率惩罚项系数较小（ $\lambda_1=\lambda_2=0.2$ ），并且模型主要仍受量价信号驱动，多周期优化的实际换手率与对照模型类似，趋近换手率约束上限。扩大惩罚系数后，可以观察到换手率显著降低，但超额收益也同步下降。

图表22：多周期优化指数增强组合回测绩效（基准为中证 500 指数）


	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
多任务学习+PLE 取平均（对照）	17.89%	5.97%	3.00	6.08%	2.94	76.14%	20.31
多任务学习+PLE 取 10 日预测	17.61%	5.91%	2.98	6.10%	2.88	80.68%	20.34
多任务学习+PLE 取 20 日预测	18.31%	5.95%	3.08	7.26%	2.52	73.86%	20.19
多任务学习+PLE+多周期优化	18.11%	5.93%	3.05	5.63%	3.22	77.27%	20.29

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

多周期优化模型中证 500 指数增强组合累计超额收益和逐月超额收益如图表 23 和 24。

图表23：多周期优化模型指数增强组合累计超额收益（基准为中证 500 指数）



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

图表24：多周期优化模型指数增强组合逐月超额收益（基准为中证 500 指数）

	1 月	2 月	3 月	4 月	5 月	6 月	7 月	8 月	9 月	10 月	11 月	12 月	年超额收益
2017 年	0.6%	0.9%	1.7%	1.1%	1.8%	4.1%	0.1%	1.1%	1.0%	5.1%	4.3%	2.5%	26.9%
2018 年	0.7%	3.9%	4.2%	0.0%	2.3%	0.9%	0.2%	-1.3%	2.6%	1.1%	5.4%	0.9%	22.8%
2019 年	0.3%	-1.5%	1.5%	2.0%	0.1%	2.4%	0.3%	-0.2%	1.7%	2.4%	1.2%	-0.3%	10.3%
2020 年	-1.8%	-0.4%	-0.6%	4.8%	3.4%	2.8%	1.3%	4.0%	1.7%	0.1%	1.0%	-0.8%	16.6%
2021 年	-1.0%	1.6%	5.0%	-0.4%	1.1%	2.8%	-0.1%	-1.5%	3.0%	0.3%	2.6%	-0.1%	14.1%
2022 年	1.8%	0.8%	-0.1%	-2.5%	5.3%	3.8%	4.9%	1.5%	-0.6%	1.8%	2.6%	1.3%	22.1%
2023 年	-1.7%	-0.1%	0.3%	-0.4%	1.2%	2.3%	-1.3%	2.3%	1.6%	0.8%	3.2%	1.3%	9.6%
2024 年	3.8%	0.5%	1.0%	0.5%									5.9%

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

中证 1000 指数增强组合回测结果如下表。多周期优化模型在超额收益、信息比率、Calmar 比率方面优于其余模型。

图表25：多周期优化指数增强组合回测绩效（基准为中证 1000 指数）


	年化超额 收益率	年化跟踪 误差	信息比率	超额收益 最大回撤	超额收益 Calmar 比率	相对基准 月胜率	年化双边 换手率
多任务学习+PLE 取平均（对照）	28.60%	6.76%	4.23	4.25%	6.74	93.18%	20.26
多任务学习+PLE 取 10 日预测	25.64%	6.66%	3.85	4.64%	5.53	84.09%	20.29
多任务学习+PLE 取 20 日预测	28.41%	6.80%	4.18	4.23%	6.71	86.36%	20.24
多任务学习+PLE+多周期优化	28.72%	6.78%	4.24	4.14%	6.93	93.18%	20.28

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

多周期优化模型中证 1000 指数增强组合累计超额收益和逐月超额收益如图表 26 和 27。

图表26：多周期优化模型指数增强组合累计超额收益（基准为中证 1000 指数）



注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

图表27：多周期优化模型指数增强组合逐月超额收益（基准为中证 1000 指数）

	1 月	2 月	3 月	4 月	5 月	6 月	7 月	8 月	9 月	10 月	11 月	12 月	年超额收益
2017 年	0.8%	1.4%	1.8%	2.7%	2.3%	6.8%	1.9%	1.4%	1.7%	4.6%	3.5%	2.2%	35.8%
2018 年	0.9%	4.9%	5.7%	2.3%	2.8%	2.2%	4.8%	0.2%	4.9%	3.2%	5.5%	2.0%	47.4%
2019 年	-1.7%	-0.5%	2.7%	1.4%	0.8%	1.4%	1.4%	0.9%	2.0%	1.8%	2.2%	-0.6%	12.4%
2020 年	0.9%	1.7%	2.4%	4.3%	3.0%	3.2%	0.6%	5.6%	2.1%	1.4%	1.0%	1.1%	30.7%
2021 年	1.4%	5.2%	2.8%	0.8%	0.6%	2.8%	-1.2%	0.0%	5.5%	1.1%	2.7%	2.4%	26.7%
2022 年	2.6%	0.8%	2.2%	-2.6%	4.2%	3.3%	2.1%	3.6%	0.5%	0.9%	3.6%	1.6%	25.3%
2023 年	-0.3%	3.9%	0.7%	0.8%	1.1%	1.2%	1.6%	1.5%	1.1%	0.8%	1.1%	1.5%	16.1%
2024 年	4.0%	3.1%	1.5%	0.9%									9.8%

注：股票池：中证全指成分股；回测区间：2016-12-30 至 2024-04-30；交易费率双边 3%；周调仓单边换手率上限 20%；优化器约束条件：80%成分内选股，行业偏离约束±2%，市值偏离约束±0.3

资料来源：Wind，华泰数智中台，华泰研究

总结

本研究从预测目标、网络结构、组合优化角度探讨多任务学习选股模型的改进。在多期限收益预测基础上，引入夏普比率作为预测目标；参考腾讯 2020 年发表的 PLE 模型，在 GRU 内部引入多层专家和门控网络；采用多周期优化融合不同期限收益预测。结果表明，改进模型相比基线均有提升，引入 PLE 总体优于引入夏普比率，PLE 结合多周期优化模型在指数增强组合的超额收益上优于大部分对照模型。回测期 2016-12-30 至 2024-04-30 内，周单边换手 20% 条件下，中证 500 增强组合年化超额收益 18.1%，信息比率 3.05，中证 1000 增强组合年化超额收益 28.7%，信息比率 4.24。

本研究的多任务学习基线模型架构为：针对日 K 线和周 K 线，分别采用多任务 GRU 网络，同时预测未来 10 日和 20 日收益率，预测值求均值视作单因子；针对分钟 K 线，人工构建 50 个因子，采用最大化 10 日 ICIR 法合成；最后将日 K 线、周 K 线和分钟 K 线因子等权合成。基线模型的预测目标仅考虑收益，未考虑风险。改进方向之一采用包含收益和风险信息的夏普比率作为目标，在 10 日和 20 日收益预测基础上，引入 20 日夏普比率预测任务。

腾讯 PCG 团队 2020 年提出 PLE（Progressive Layered Extraction）架构，采用多层专家和门控网络设计，提升特征表征能力。改进方向之二将 PLE 引入基线模型的双层 GRU 网络。其中，第一层的任务共享专家网络和任务特定专家网络接受相同的原始 K 线输入信息，采用单层 GRU 提取浅层特征表征后，通过第一层门控单元进行融合；第二层的任务共享专家网络和任务特定专家网络接受特异的输入信息，采用单层 GRU 提取深层特征表征后，通过第二层门控单元进行融合。门控单元均采用单层 GRU 网络与 Softmax 激活。后续的任务特异层与基线模型一致。

多任务学习同时预测不同期限收益率，基线模型直接求均值作为最终预测，缺点是投资意义不明确。改进方向之三采用多周期优化技术，将 10 日和 20 日收益预测同时输入组合优化器。单周期优化中，每期组合优化的目标函数为最大化预期收益。多周期优化中，目标函数除了最大化预期收益项外，还加入了换手率惩罚项。在最大化组合短期收益和长期收益的同时，限制组合当期换手以及下期可能的换手。

测试结果表明，三项改进相比基线均有提升。从 GRU 单因子看，引入夏普比率和引入 PLE 均优于对应的基线。从指数增强组合看，引入 PLE 总体优于引入夏普比率。将“多任务学习+PLE 取 10 日预测”与“多任务学习+PLE 取 20 日预测”的预测值作为多周期优化的输入变量，构建中证 500 和中证 1000 指数增强组合，超额收益优于大部分对照模型，同时在回撤控制上体现出优势。回测期 2016-12-30 至 2024-04-30 内，周单边换手 20% 条件下，中证 500 增强组合年化超额收益 18.1%，信息比率 3.05，超额收益 Calmar 比率 3.22；中证 1000 增强组合年化超额收益 28.7%，信息比率 4.24，超额收益 Calmar 比率 6.93。

本研究存在如下未尽之处：（1）引入夏普比率和引入 PLE 的改进原因未深入探索。例如，夏普比率标签的意义是否仅仅起到缓解过拟合的作用，而非学到了风险信息？PLE 的意义是否仅仅提升了模型复杂度，而非促进了特征表征的学习？从学术研究角度，或可进一步通过对照实验分析。（2）量价数据预测周期通常较短，可结合基本面数据进行更长期限的预测，使用多周期优化，可能是融合量价和基本面信息的有效途径。

参考文献

- Boyd, S., Busseti, E., Diamond, S., Kahn, R. N., Koh, K., Nystrup, P., & Speth, J. (2017). Multi-period trading via convex optimization. *Foundations and Trends in Optimization*, 3(1), 1-76.
- Liu, S., Johns, E., & Davison, A. J. (2019). End-to-end multi-task learning with attention. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 1871-1880).
- Tang, H., Liu, J., Zhao, M., & Gong, X. (2020). Progressive layered extraction (PLE): A novel multi-task learning (MTL) model for personalized recommendations. In *Proceedings of the 14th ACM Conference on Recommender Systems* (pp. 269-278).

风险提示

人工智能挖掘市场规律是对历史的总结，市场规律在未来可能失效。人工智能技术存在过拟合风险。深度学习模型受随机数影响较大。本文测试的选股模型调仓频率较高，假定以vwap价格成交，忽略其他交易层面因素影响。

免责声明

分析师声明

本人，林晓明、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。

一般声明及披露

本报告由华泰证券股份有限公司（已具备中国证监会批准的证券投资咨询业务资格，以下简称“本公司”）制作。本报告所载资料是仅供接收人的严格保密资料。本报告仅供本公司及其客户和其关联机构使用。本公司不因接收人收到本报告而视其为客户。

本报告基于本公司认为可靠的、已公开的信息编制，但本公司及其关联机构(以下统称为“华泰”)对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰不保证本报告所含信息保持在最新状态。华泰对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰没有将此意见及建议向报告所有接收者进行更新的义务。华泰的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为本公司所有。未经本公司书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人(无论整份或部分)等任何形式侵犯本公司版权。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。本公司保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司制作,在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题,请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 https://www.htsc.com.hk/stock_disclosure 其他信息请参见下方 “美国-重要监管披露”。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934年证券交易法》（修订版）第15a-6条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师林晓明、何康本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第32C条的规定分发其在华泰内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或所分发的信息相关的事宜。

评级说明

投资评级基于分析师对报告发布日后6至12个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A股市场基准为沪深300指数，香港市场基准为恒生指数，美国市场基准为标普500指数，台湾市场基准为台湾加权指数，日本市场基准为日经225指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数），具体如下：

行业评级

增持：预计行业股票指数超越基准

中性：预计行业股票指数基本与基准持平

减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准15%以上

增持：预计股价超越基准5%~15%

持有：预计股价相对基准波动在-15%~5%之间

卖出：预计股价弱于基准15%以上

暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国：华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格，经营许可证编号为：91320000704041011J

香港：华泰金融控股（香港）有限公司具有香港证监会核准的“就证券提供意见”业务资格，经营许可证编号为：AOK809

美国：华泰证券（美国）有限公司为美国金融业监管局（FINRA）成员，具有在美国开展经纪交易商业业务的资格，经营业务许可编号为：CRD#:298809/SEC#:8-70231

新加坡：华泰证券（新加坡）有限公司具有新加坡金融管理局颁发的资本市场服务许可证，并且是豁免财务顾问。公司注册号：202233398E

华泰证券股份有限公司

南京

南京市建邺区江东中路228号华泰证券广场1号楼/邮政编码：210019

电话：86 25 83389999/传真：86 25 83387521

电子邮件：ht-rd@htsc.com

深圳

深圳市福田区益田路5999号基金大厦10楼/邮政编码：518017

电话：86 755 82493932/传真：86 755 82492062

电子邮件：ht-rd@htsc.com

北京

北京市西城区太平桥大街丰盛胡同28号太平洋保险大厦A座18层/

邮政编码：100032

电话：86 10 63211166/传真：86 10 63211275

电子邮件：ht-rd@htsc.com

上海

上海市浦东新区东方路18号保利广场E栋23楼/邮政编码：200120

电话：86 21 28972098/传真：86 21 28972068

电子邮件：ht-rd@htsc.com

华泰金融控股（香港）有限公司

香港中环皇后大道中99号中环中心53楼

电话：+852-3658-6000/传真：+852-2567-6123

电子邮件：research@htsc.com

http://www.htsc.com.hk

华泰证券（美国）有限公司

美国纽约公园大道280号21楼东（纽约10017）

电话：+212-763-8160/传真：+917-725-9702

电子邮件：Huatai@htsc-us.com

http://www.htsc-us.com

华泰证券（新加坡）有限公司

滨海湾金融中心1号大厦，#08-02，新加坡 018981

电话：+65 68603600

传真：+65 65091183

©版权所有2024年华泰证券股份有限公司